

Estudio de Sinergias Musculares

Selección Óptima de Topología de Sensores EMG para
Control Robótico y Análisis Biomecánico

Autor: Alejandro Solar Iglesias

Fecha: Enero 2026

Metodología: NNMF + Auditoría SNR + Pearson

Nota: Este documento describe el flujo de trabajo computacional y utiliza un caso de estudio real a modo de ilustración.

Índice

1. Introducción	2
2. Metodología Científica	2
2.1. Etapa 1: Auditoría de Calidad (SNR)	2
2.2. Etapa 2: Detección de Redundancia (Pearson)	2
2.3. Etapa 3: Extracción de Sinergias (NNMF)	2
3. Aplicación Práctica: Caso de Estudio	3
3.1. Ejecución de Calidad y Redundancia	3
3.2. Extracción Automática de Sinergias (VAF)	4
3.3. Generación del Ranking de Importancia	5
4. Conclusiones sobre la Metodología	6

1. Introducción

El objetivo de este informe es determinar la selección óptima de sensores electromiográficos (EMG) para la captura de actividad muscular en extremidad superior. Dado que el sistema nervioso central (SNC) no controla los músculos de forma aislada, sino mediante módulos de activación coordinada denominados *sinergias musculares* [1, 3], es posible reducir la dimensionalidad del sistema de adquisición sin pérdida significativa de información de control.

Este documento detalla el procedimiento algorítmico utilizado para filtrar, analizar y clasificar la relevancia de 12 sensores musculares (Noraxon), descartando aquellos que presentan redundancia funcional o baja relación señal-ruido. **A lo largo de las siguientes secciones, se utilizará un registro real a modo de caso práctico para ilustrar el funcionamiento del pipeline.**

2. Metodología Científica

Se ha implementado un algoritmo híbrido en Python que integra tres etapas de validación, fundamentadas en la literatura biomecánica actual:

2.1. Etapa 1: Auditoría de Calidad (SNR)

Antes de cualquier análisis funcional, se audita la calidad técnica de la señal basándose en los estándares de la Sociedad Internacional de Electrofisiología y Kinesiología (ISEK). Según **Konrad (2005)**, el ruido basal (baseline noise) debe mantenerse por debajo de un umbral crítico para asegurar la validez de los datos:

$$Ruido_{RMS} < 5\mu V \quad (\text{Criterio de Calidad Óptima}) \quad (1)$$

Cualquier sensor que supere los $15\mu V$ en reposo es marcado como *Crítico* y descartado por fallo de impedancia o contacto.

2.2. Etapa 2: Detección de Redundancia (Pearson)

Se calcula la matriz de correlación de Pearson (r) entre todos los pares de sensores activos para detectar *colinealidad cinemática*. Un coeficiente $r > 0,90$ indica que dos músculos aportan información redundante para la tarea específica, permitiendo la simplificación del hardware.

2.3. Etapa 3: Extracción de Sinergias (NNMF)

Para identificar la estructura de control motor, se aplica el algoritmo de **Factorización de Matrices No Negativas (NNMF)** propuesto por **Lee & Seung (1999)**. Este método descompone la matriz de señales EMG (E) en dos matrices de menor dimensión:

$$E \approx W \times H \quad (2)$$

Donde:

- **W (Matriz de Pesos):** Indica la contribución espacial de cada músculo a la sinergia.

- **H (Matriz de Activación):** Representa los comandos temporales del SNC.

La dimensionalidad óptima (número de sinergias) se determina mediante el criterio de la **Varianza Explicada (VAF)**, estableciendo que el modelo es válido si reconstruye más del 90 % de la señal original, según el protocolo de **Yokoyama et al. (2019)** [2] y **Torres-Oviedo (2007)** [4].

3. Aplicación Práctica: Caso de Estudio

Para demostrar la eficacia del algoritmo descrito, se procedió a procesar un conjunto de datos correspondiente a una tarea de prueba (*PRUEBA MANUAL*), capturado mediante un sistema de 12 canales.

3.1. Ejecución de Calidad y Redundancia

El procesado automatizado de las 76.747 muestras útiles arrojó los siguientes resultados ilustrativos:

- **Calidad de Señal:** El script auditó el ruido basal de los sensores, validando la toma para continuar el análisis funcional.
- **Redundancia:** A diferencia de configuraciones ideales, el algoritmo detectó una **alta redundancia funcional** ($r = 0,90$) entre el *Extensor Ulnaris* y el *Flexor Ulnaris*. Esto genera una alerta automática en el sistema, indicando al investigador que uno de los dos sensores podría eliminarse en futuros ensayos sin perder información cinemática relevante.

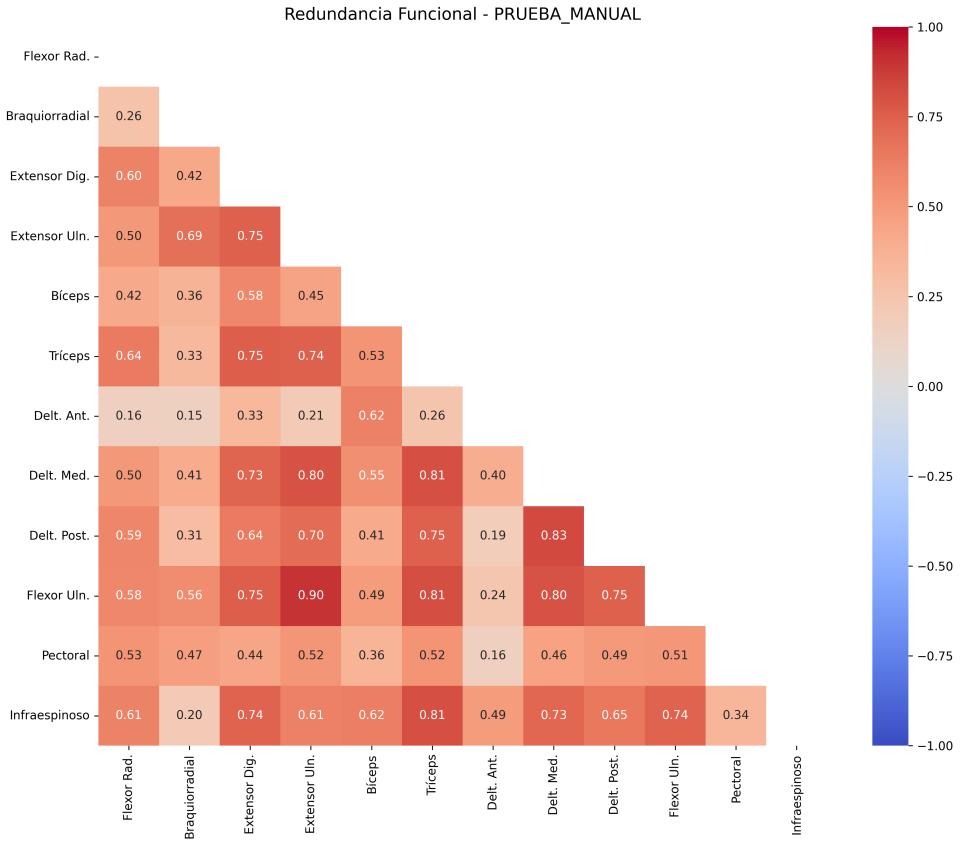


Figura 1: Ejemplo de salida del módulo de redundancia (Matriz de Pearson). El sistema marca automáticamente las correlaciones críticas ($r \geq 0.90$).

3.2. Extracción Automática de Sinergias (VAF)

Al aplicar el módulo NNMF a la muestra de prueba, el algoritmo iteró hasta encontrar el número mínimo de comandos necesarios para superar el umbral científico del 90 % de VAF. En este caso de estudio, la complejidad del movimiento se redujo de forma muy eficiente a **3 comandos de control** (Tabla 1 y Figura 2).

Nº Sinergias (Prueba)	VAF Calculado	Criterio (> 90 %)	Decisión del Algoritmo
1	79.79 %	No	Rechazado
2	87.52 %	No	Rechazado
3	92.23 %	Sí	Selección Óptima

Cuadro 1: Proceso iterativo de cálculo de VAF ejecutado por el algoritmo. El criterio se alcanzó tempranamente en la tercera iteración.

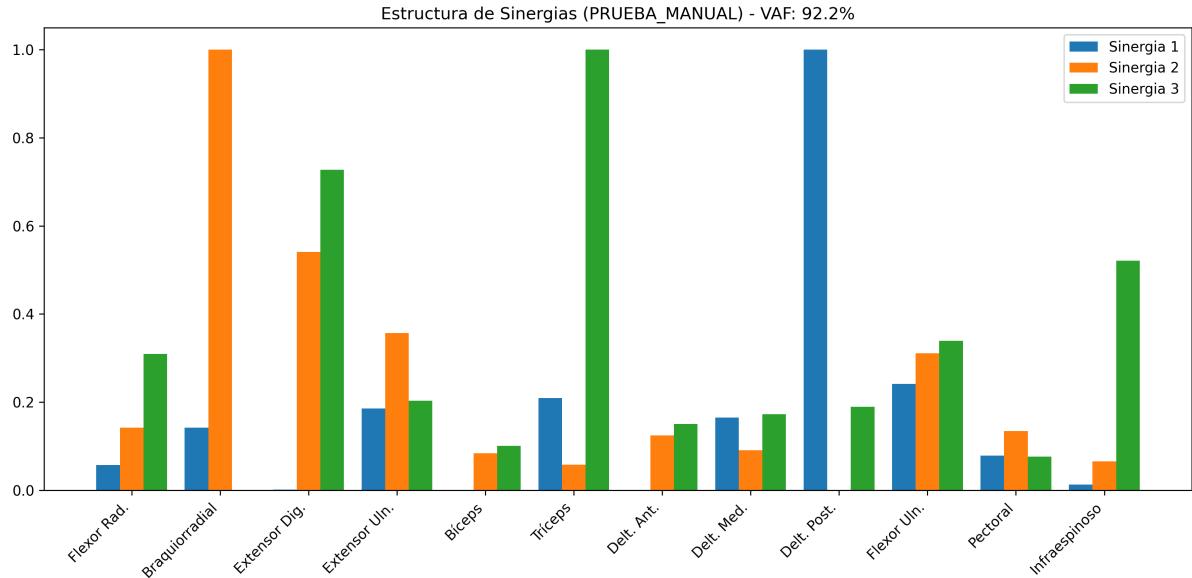


Figura 2: Representación gráfica de la matriz de pesos (W) generada por el algoritmo, mostrando la estructura interna de las 3 sinergias encontradas en la tarea de ejemplo.

3.3. Generación del Ranking de Importancia

Como paso final del pipeline, el software extrae los sensores con mayor y menor peso global. La Tabla 2 y la Figura 3 muestran cómo el sistema clasificó automáticamente los músculos para esta tarea específica, revelando un patrón enfocado en la extensión y estabilización del hombro posterior.

Músculo Analizado	Clasificación Algorítmica
1. Extensor Digitorum	Crítico (Top 1)
2. Tríceps	Crítico (Top 2)
3. Delt. Post.	Crítico (Top 3)
4. Braquiorradial	Relevante (Top 4)
5. Flexor Uln.	Relevante (Top 5)
6. Otros (Delt. Med., Flexores...)	Aporte Medio
10. Pectoral	Candidato a Descarte
11. Delt. Ant.	Candidato a Descarte
12. Bíceps	Candidato a Descarte

Cuadro 2: Ranking automatizado de selección de sensores devuelto por el sistema para la prueba manual.

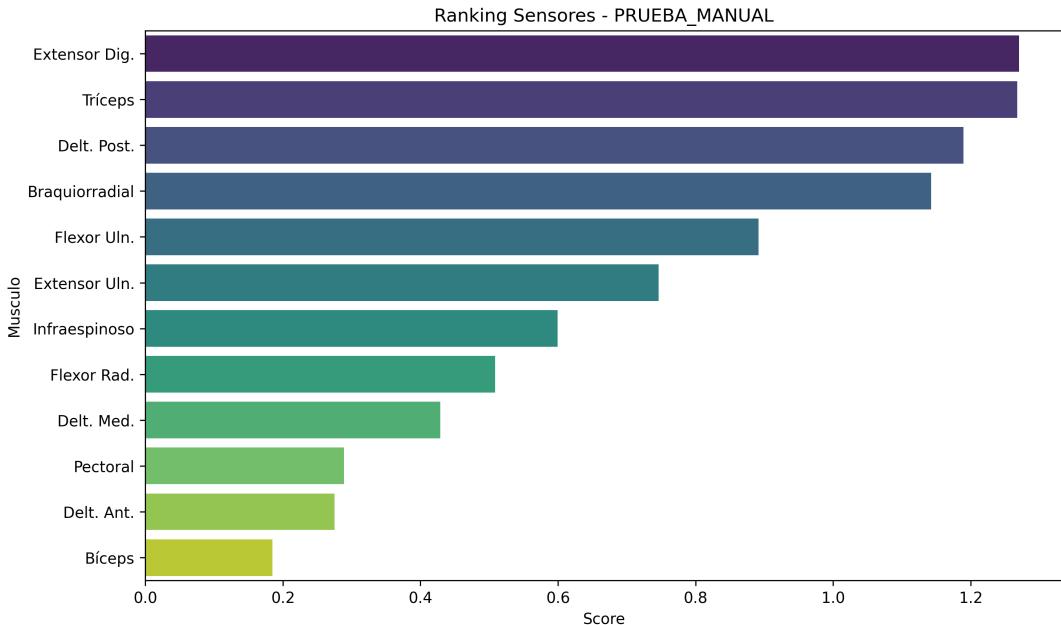


Figura 3: Visualización del ranking final de sensores, facilitando la toma de decisiones sobre qué hardware eliminar en futuros ensayos.

4. Conclusiones sobre la Metodología

La aplicación de esta arquitectura computacional al caso de estudio demuestra la viabilidad de utilizar técnicas de aprendizaje automático (NNMF) y análisis estadístico para auditar y optimizar equipos de medición biomecánica.

De forma general, este *pipeline* proporciona las siguientes ventajas operativas:

- 1. Detección de Redundancias Ocultas:** El módulo de Pearson demostró su utilidad al alertar sobre una redundancia cinemática ($r = 0,90$) entre los músculos ulnares, permitiendo al investigador liberar un canal EMG en el hardware sin impacto en la calidad del estudio.
- 2. Decisiones Basadas en Datos (Data-Driven):** El sistema elimina la subjetividad anatómica. En el ejemplo procesado, el algoritmo identificó matemáticamente que la tarea dependía de la extensión (*Extensor Digitorum*, *Tríceps*) y la tracción posterior (*Delt. Post.*), mientras que sensores tradicionalmente importantes como el *Biceps* o el *Pectoral* mostraron una contribución marginal y fueron propuestos para descarte.
- 3. Escalabilidad:** El flujo de trabajo documentado (Auditoría → Pearson → VAF → Ranking) es genérico, totalmente automatizado y agnóstico respecto a la articulación estudiada, permitiendo su aplicación directa en el procesado masivo de datos para robótica colaborativa o ergonomía.

Referencias

- [1] Pertusa Llopis, A. M. (2020). *Estudio de sinergias musculares durante actividades de pedaleo*. Trabajo Fin de Grado, Universidad de Alicante. Disponible en: <http://hdl.handle.net/10045/108354>
- [2] Yokoyama, H., Kaneko, N., Ogawa, T., Kawashima, N., Shinya, M., & Nakazawa, K. (2019). *Cortical Correlates of Locomotor Muscle Synergy Activation in Humans: An Electroencephalographic Decoding Study*. iScience, 15, 623-639. Disponible en: <https://doi.org/10.1016/j.isci.2019.04.008>
- [3] Saito, A., Tomita, A., Ando, R., Watanabe, K., & Akima, H. (2018). *Similarity of muscle synergies extracted from the lower limb including the deep muscles between level and uphill treadmill walking*. Gait & Posture, 59, 134-139. Disponible en: <https://doi.org/10.1016/j.gaitpost.2017.10.007>
- [4] Torres-Oviedo, G., & Ting, L. H. (2007). *Muscle Synergies Characterizing Human Postural Responses*. Journal of Neurophysiology, 98(4), 2144-2156. Disponible en: <https://doi.org/10.1152/jn.01360.2006>